



Artículo.

Gestión de reputación online: Activision Blizzard y Uber frente a incidentes relacionados con el acoso sexual.

Alejandro Albarracin Rojas.¹

¹ Master en Data Science, Universidad de Alcalá (UAH), albarra1591@gmail.com

Abstract: Las redes sociales se han convertido en una fuente de datos de gran utilidad para las empresas, estas plataformas ofrecen información fiable sobre el sentir del público hacia las marcas y sus productos. En este proyecto se emplearon datos extraídos de Twitter junto a técnicas de análisis de sentimiento y topic modelling, con el objetivo de examinar como incidentes relacionados con el acoso sexual afectaron a la reputación de las compañías Uber y Activision Blizzard. A lo largo del estudio, se testearon tres algoritmos de clasificación y diferentes tipos de limpieza de texto antes de utilizarse en los datos extraídos, concluyendo que el modelo siberett/roberta-sentiment-analysis-finetune es el más efectivo. Los resultados reflejaron una reducción considerable de la reputación en el caso de Activision Blizzard tras el suceso de los incidentes. Por otro lado, en el caso Uber se observó la continuidad de una tendencia negativa en su reputación, al encadenar este incidente con otro suceso que ya afectaba de forma adversa la imagen de la marca.

Keywords: NPL, Sentiment Analysis, Brand reputation, Online Reputation Management, BERT, Transformers, Topic Modeling.

1. Introduction

El uso cotidiano de las redes sociales se ha consolidado en gran parte de la población mundial. Algunas de estas plataformas son utilizadas regularmente por los individuos como medio para expresar sus opiniones, lo que las convierte en una fuente de datos fiable de la cual es posible extraer información acerca del sentir de las personas.

El análisis de sentimiento es una técnica PNL utilizada para identificar la polaridad de las emociones en textos, videos o imágenes. El *Bussiness Inteligence* es una de las disciplinas que mayor provecho le saca a esta tecnología, permitiendo a las empresas evaluar la aceptación de un determinado producto, analizar la percepción que tienen los clientes sobre sus servicios o valorar los resultados de una campaña de marketing. Esta información facilita a las empresas el poder responder y actuar en consecuencia a las reacciones de sus consumidores.

La finalidad de este proyecto es analizar cómo la reputación de una marca se ve afectada ante incidentes relacionados con el abuso sexual dentro de la compañía. En concreto, se van a estudiar dos casos, el primero, relacionado con la demanda por acoso sexual interpuesta por el Departamento de Igualdad en el Empleo y la Vivienda del Estado de California en contra de la compañía de video juegos Activision Blizzard el 20 de julio de 2021. El segundo caso, vinculado a la publicación de un blog por parte de una extrabajadora de Uber el 19 de febrero de 2017, en el cual denuncia haber sufrido acoso sexual por parte de sus supervisores y la inacción de los directivos. Para llevar a cabo este

proyecto se utilizan datos extraídos de Twitter, red social de *microblogging*. Estos datos contienen tweets en los que han sido mencionadas las cuentas de las marcas, un mes antes y un mes después de que ocurran los hechos a estudiar.

El proyecto cuenta con dos objetivos principales. El primero, se centra en realizar un análisis de reputación. Aplicaremos la metodología PLN de análisis de sentimiento con el propósito de medir el prestigio de las marcas. Para ello, clasificaremos los comentarios extraídos de Twitter, determinaremos su polaridad y compararemos los resultados de estas mediciones antes y después de que ocurran los acontecimientos estudiados, lo que nos permitirá concluir si la imagen de las marcas ha sido afectada por estos hechos. Para las empresas, a la hora de crear una estrategia, el entendimiento de su comunidad es un punto clave a tener en cuenta a fin de ser capaces de responder rápidamente a cambios de opinión de sus consumidores, adaptarse a las necesidades de su público y prevenir oleadas negativas. Las redes sociales se han transformado en una valiosa herramienta para seguir y monitorear el feedback de una comunidad, por este motivo los datos utilizados los obtendremos de Twitter, una de las redes sociales con más actividad a nivel mundial.

El segundo objetivo está enfocado en obtener las ideas subyacentes dentro de nuestros corpus de texto. Se identificarán los temas que se encuentran con mayor frecuencia en cada set de datos y los compararemos con la intención de descubrir un cambio de temática. No solo se busca una medida cuantitativa de la reputación de la marca, sino que también, un profundo entendimiento de los datos.

2. Estado del Arte.

El Procesamiento del Lenguaje Natural es un campo ampliamente estudiado, campo que ha experimentado un desarrollo enorme desde sus inicios, extendiendo sus aplicaciones a diversas ramas, dentro de las que se encuentran el *Machine Translation*, el *Spam Filtering*, el *Question Answering* o el *Sentiment Analysis*, entre diversas más. En los años recientes, el área del PNL ha experimentado una evolución significativa, este progreso se debe fundamentalmente al uso de técnicas como el transfer learning y la arquitectura Transformer, presentada por Vaswani et al. en 2017 en el artículo “Attention is all you need” [1], basada fundamentalmente en los mecanismos de atención. Transformer se ha convertido rápidamente en la arquitectura dominante en el procesamiento del lenguaje natural, superando a otras alternativas en el desempeño de tareas, tanto de entendimiento como de generación del lenguaje natural [2]. Por este motivo, nos centraremos en examinar la literatura en busca de estudios con una temática similar a la de nuestro proyecto y que, además, hagan uso de la arquitectura Transformer.

Hyunji Kim, en su trabajo “A study on Brand image analysis of gaming bussines corporation using KoBERT and Twitter data” [3], define la reputación de una compañía como la manera en que los grupos de interés reconocen una marca. El estudio se centra en analizar la imagen de cinco compañías de video juegos coreanas, sector clave en la industria del software y contenido digital del país. La autora, resalta la necesidad que tienen las empresas de instaurar una metodología que les haga posible entender el grado de satisfacción de sus consumidores de forma frecuente, permitiéndoles sustituir los

métodos tradiciones de análisis de reputación, siendo estos, poseedores de grandes limitaciones relacionadas con la escasez de datos, subjetividad en los análisis y dificultad en las evaluaciones relativas con competidores. El proyecto se desarrolla en base a tres metodologías claves; el transfer learning, la arquitectura Transformer y KoBERT. En el análisis se utilizan las cinco mejores compañías del “Korea Corporate Reputation Research Institute Data Lab” de diciembre de 2020. Los datos usados para el experimento son tweets extraídos mediante la API de Twitter en el periodo de diez al quince de diciembre de 2020, utilizando como consulta el nombre de las compañías. La fase de preprocesamiento de datos se centra en eliminar información innecesaria como espacios extras, urls, texto en inglés y caracteres especiales, para a continuación emplear con un test de errores de escritura. En la fase de entrenamiento se realiza un *fine-tune* del modelo KoBERT, empleando doscientas mil reseñas de películas, etiquetando como negativas las películas con un rating de 1 a 4 y como positivas las películas con un rating de 6 a 10. De estos datos se utilizan 150000 para el entrenamiento y 50000 para el test, donde el modelo reportó un 88% de *accuracy*.

Mohammad Wali Ur Rahman et al. en su trabajo “A BERT-based Deep Learning approach for reputation análisis in social media”[4], destacan, la consolidación del análisis de reputación online en las grandes empresas y su transformación en una parte integral de las estrategias de marketing, permitiendo a las compañías superar las limitaciones de los métodos tradicionales de análisis de reputación, limitaciones vinculadas a la subjetividad de los datos obtenidos o el retraso entre la ocurrencia de los eventos y su publicación. El objetivo de este estudio es analizar el desempeño del modelo pre-entrenado BERT usando el RepLab 2013 dataset, para comparar sus resultados con los de otros modelos anteriormente utilizados. La fase de preprocesamiento de texto está enfocada en eliminar espacios extras, caracteres especiales, emojis, urls, links y signos de puntuación. En la fase de análisis se realizan tres experimentos utilizando diferentes variantes del modelo BERT. El primer experimento utiliza el set de entrenamiento completo del RepLab dataset y lo emplea para realizar un *fine-tune* sobre el bert-base-multilingual-uncased-model. En el segundo experimento, se utiliza la API de Twitter para clasificar el set de entrenamiento por idiomas, con el fin de entrenar dos modelos diferentes, el bert-large-uncased-model entrenado con los textos en inglés y el modelo bert-base-multilingual-uncased-model con los textos en español. El tercer experimento es similar al anterior, utiliza el mismo enfoque para los textos en español, pero para los textos en inglés, utiliza el bert-uncased-model en lugar del bert-large-uncased-model. El estudio reportó unos resultados similares entre los experimentos, destacando el segundo con un 73% de *accuracy*. Al compararlo con el modelo con el mejor desempeño de estudios anteriores se obtiene una mejora en el *accuracy* del 4%.

3. Materiales y Métodos.

Este proyecto se estructuró de la siguiente forma. Primero, se extrajeron de Twitter los datos referentes a las compañías a estudiar, a continuación, se entrenaron los algoritmos a utilizar empleando el TweetEval dataset [5], para luego comparar sus

resultados utilizando como métricas de referencia el *accuracy* y el *macro avg F1 score*. Una vez se obtuvo el modelo con el mejor desempeño, se empleó en los datos adquiridos, permitiéndonos clasificar los tweets según su polaridad y obtener una medida de reputación. Esta medida de reputación toma valores entre 1 y -1, donde los valores cercanos a 1 nos muestra un reconocimiento muy positivo por parte del público, valores cercanos a cero indican una opinión neutra y valores en torno a -1 señala un sentimiento muy negativo.

$$\text{Indice de Reputacion} = \frac{\text{Tweets Positivos} - \text{Tweets negativos}}{\text{Tweets Positivos} + \text{Tweets negativos}}$$

3.1. Datos.

3.1.1 Recolección de datos.

Para la fase de recolección de datos, se consideraron dos métodos, el uso de la API de Twitter a través de la librería Tweepy y la librería snsrape [6], especializada en extraer información de las redes sociales. Se eligió la segunda opción debido a las múltiples limitaciones que presenta la API de Twitter para su uso. Las consultas se realizaron utilizando el nombre de las cuentas vinculadas a las compañías en Twitter. Para el caso Uber se extrajeron tweets comprendidos entre el periodo del 20 de enero de 2017 al 20 de marzo de 2017, obteniéndose un total de 107254 tweets. En el caso Activision Blizzard los tweets se encuentran incluidos en el periodo del 20 de mayo de 2021 al 20 de julio de 2021, obteniéndose 23056 tweets. Estos datos se dividieron en dos datasets, utilizándose como condición la fecha en que ocurren los hechos a estudiar. Se usó como criterio de exclusión los tweets escritos en idiomas distintos al inglés. Los datasets cuentan con otras 6 variables complementarias al texto, Fecha, Usuario, Localización, Numero de Likes y Numero de Retweets.

3.1.2. Tweet Eval.

Tweet Eval es un corpus de texto ofrecido por Huggingface [7] destinado a la clasificación de tweets con múltiples etiquetas. Este corpus contiene siete sets de datos utilizados en diferentes tareas de clasificación (*irony, hate, offensive, stance, emoji, emotion, and sentiment*). Teniéndose como objetivo comparar el desempeño de los modelos a utilizar, se empleó el *sentiment set*, conformado por un total de 59899 tweets debidamente etiquetados, con valor 0 para los tweets con un sentimiento negativo, 1 para los tweets con un sentimiento neutro y 2 para los que tiene un sentimiento positivo.

3.2. Limpieza de datos.

Con la intención de comprobar que tipo de procesamiento de texto es el más apropiado para los modelos a utilizar y las características de nuestro texto, se proponen tres formas diferentes de limpieza de texto.

3.2.1. Limpieza tipo 1.

Se transforman todas las letras del texto en minúsculas y se eliminan los caracteres fuera del formato ASCII. Se remueven las urls, nombres de usuarios, hashtags y signos de puntuación. Se omiten las palabras con menos de dos caracteres. Se utiliza la librería *jampell* [8] para realizar un *spell-check* y corregir errores de escritura. Para finalizar suprimimos las palabras vacías presentes en el texto y aplicamos la técnica de lematización.

3.2.2. Limpieza tipo 2.

Se realiza una normalización del texto en minúsculas. Se remueven las urls, nombre de usuarios, hashtag y signos de puntuación. Se aplica el *spell-check* y, por último, se omiten las palabras con menos de dos caracteres.

3.2.3. Limpieza tipo 3.

Se remueven las urls y los nombres de usuarios. Se omiten todos los caracteres especiales y signos de puntuación exceptuando las comas, los puntos y los signos de exclamación. Para finalizar se aplica el *spell-check*.

3.3. Elección de Modelos.

3.3.1. Support Vector Machines

Las Support Vector Machines es uno de los algoritmos clásicos dentro del aprendizaje supervisado, empleado tanto en labores de clasificación como regresión. Las SVMs han mostrado tradicionalmente su efectividad en tareas de clasificación de texto; Las SVMs reconocen las propiedades particulares del texto: espacio de variables de gran dimensión, pocas variables irrelevantes y vectores con una pequeña cantidad de números distintos a cero [9]. Los mejores resultados del modelo se alcanzaron utilizando la Limpieza Tipo 2. Las representaciones vectoriales de las palabras se obtuvieron empleando la técnica TF-IDF. El modelo se entrenó utilizando el método Grid Search, obteniéndose como mejor combinación de hiperparámetros {C=1, gamma=1 y kernel=linear} y reportando una *accuracy* del 67,5% y un *macro avg f1 score* de 63,7%.

Tabla 1. Informe de las principales métricas de clasificación del modelo SVMs por clases.

Clase	Precision	Recall	F-1
Negativa	0.560	0.458	0.504
Neutra	0.644	0.762	0.698
Positiva	0.759	0.664	0.708

3.3.2. roBERTa

roBERTa [10] es una optimización del modelo BERT [11], modelo desarrollado en 2018 por investigadores del Google AI Language basado en la arquitectura Transformer. BERT revolucionó el espacio del PLN al resolver 11 de sus tareas más comunes (y mejorar los resultados de modelos anteriores), convirtiéndolo en el modelo a utilizar en la mayoría de las tareas PNL [12]. En concreto, se utilizó el modelo preentrenado *cardiffnlp/twitter-roberta-base-sentiment-latest* [13] basado en roBERTa y *fine-tune* para el análisis de

sentimiento mediante el uso de más de 124 millones de tweets. Se encuentra listo para su uso y es ofrecido de forma abierta por Huggingface. Los mejores resultados del modelo se obtuvieron utilizando la Limpieza tipo 3, reportando una *accuracy* de 71,3% y un *macro avg F1 score* de 71,4%. A continuación, se procedió a realizar un *fine-tune* de este modelo con el objetivo de mejorar su desempeño. El *siberett/roberta-sentiment-analysis-finetune*, utilizó como hiperparámetros: {batch size=64, learning rate=1e-5, epochs=10, weight decay=0.01}, reportando un *accuracy* del 72,1% y un *macro avg f1 score* de 72,2%.

Tabla 2. Informe de las principales métricas de clasificación del modelo Siberett/ por clases.

Clase	Presicion	Recall	F-1
Negativa	0.725	0.752	0.738
Neutra	0.743	0.684	0.712
Positiva	0.674	0.765	0.717

3.3.3 XLnet.

XLnet es otro modelo basado en la arquitectura Transformer. Xlnet integra en el preentrenamiento los mecanismos de segmentos recurrentes y el esquema de codificación relativa de Transformer-XL; Xlnet es un Transformer autorregresivo que aprovecha lo mejor del modelado del lenguaje autorregresivo y la codificación automática, intentando evitar sus limitaciones [14]. Este modelo combina el uso de los contextos bidireccionales, utilizados por BERT, con la tecnología autorregresiva del modelo Transformer-XL, consiguiendo mejorar los resultados de BERT en 20 tareas NPL diferentes. Se realizó un *fine-tune* sobre el modelo XLnet utilizando el Tweet Eval dataset, con el objetivo de emplearlo en tareas de clasificación. Los hiperparámetros utilizados fueron: {batch size=32, learning rate=2e-5, epochs=5, weight decay=0.001}, obteniéndose una *accuracy* del 69,5% y un *macro avg f1 score* de 69,4%.

Tabla 3. Informe de las principales métricas de clasificación del modelo Xlnet por clases.

Clase	Presicion	Recall	F-1
Negativo	0.699	0.729	0.714
Positivo	0.723	0.658	0.689
Neutro	0.635	0.731	0.679

3.3.4 Elección de modelo.

Se eligió el modelo *siberett/roberta-sentiment-analysis-finetune*. La Tabla 4 muestra una comparación de las métricas de referencia obtenidas en cada modelo. A la hora de entrenar los modelos basados en la arquitectura Transformer se identificó cierto *overfitting* a pesar de obtener un buen desempeño. Se intentó incrementar el dropout de los modelos empeorando los resultados de estos. Este comportamiento parece ser estar relacionado con la gran cantidad de parámetros de los modelos y la necesidad de más datos para su entrenamiento.

Tabla 4.

Clase	Acuraccy	F1
SVM	67,5	63,7
cardiffnlp/twitter-roberta-base-sentiment-latest	71,3	71,4
siberett/roberta-sentiment-analysis-finetune	72,1	72,2
Xlnet	69,4	69,5

3.4. Topic Modeling.

Topic Modeling es una técnica de aprendizaje no supervisado empleada en el Procesamiento del Lenguaje Natural para identificar las ideas subyacentes dentro de grandes volúmenes de texto. Esta técnica, se aplica en diversas tareas dentro de las cuales, se encuentran el *text classification* o el *document summarization*. Los modelos clásicos utilizados en el Topic Modeling, son los modelos de enfoque probabilístico tales como el LDA y el LSA [15]. Con el fin de hallar los temas principales en nuestros datos, se utilizará la librería BERTopic [16]. BERTopic consta de cuatro componentes clave: el uso de *Transformers embeddings* para vectorizar el texto, UMAP para reducir las dimensiones de estos vectores, HDBSCAN para clusterizar los datos y el uso de c-TF-IDF para extraer los *topics* de cada cluster.

4. Resultados.


Una vez implementados los algoritmos a utilizar y asignadas las etiquetas a los conjuntos de datos extraídos, se procedió a calcular el índice de reputación de las compañías y analizar los tweets.

4.1. Activision Blizzard.

La Figura 1 muestra un cambio en la distribución de polaridad de los tweets referentes a Activision Blizzard. Antes de la denuncia por parte del Estado de California en contra de la compañía, se observa una distribución de sentimiento equitativa (34.6% Negativa, 34.9% Positiva y 30.5% Neutra). Una vez ocurrido este suceso, el sentimiento negativo pasa a dominar la distribución con un 57.4%. El índice de reputación pasa de tener un valor en torno a cero a ser -0.55.

Figura 1.


Distribucion De La Polaridad de los Tweets (Activision Blizzard)




Al comparar la Figura 2 con la Figura 3, se observa un incremento significativo en la cantidad de tweets escritos entre periodos, siendo la media diaria de 202 tweets antes de los hechos y de 541 después de estos. También se observa un claro impacto en los tweets negativos una vez ocurren los hechos.

Figura 2.

Distribucion Diaria de los Tweets Antes de los Hechos (Activision Blizzard).

**Figura 3.**

Distribucion Diaria de los Tweets Despues de los Hechos (Activision Blizzard).



En al análisis de los contenidos subyacentes en el texto, se identificó un cambio en la temática de estos. Los temas principales antes del suceso, están relacionados con los productos de la compañía y sus videojuegos. Una vez acontecidos los hechos, se pueden identificar temas relacionados al “acoso sexual”, “demanda judicial” e insultos hacia la


compañía. Este cambio de temática también se reflejó en las estadísticas del texto, con la presencia de términos como “mujer”, “empleada” o “sexual” dentro de las 50 palabras más utilizadas, palabras que antes no se encontraban. A su vez el n-grama de grado dos que más apareció después del suceso es “sexual harassment”.

4.2. Uber.

En la figura 4 vemos una distribución de polaridades muy parecida antes y después de la publicación del blog por parte de la extrabajadora. El índice de reputación no varía y se mantiene en torno a -0.45.

Figura 4.

Distribucion De La Polaridad de los Tweets (Uber)



Al analizar la Figura 5 y la Figura 6, se identificó claramente el impacto negativo de los sucesos estudiados sobre la imagen de la marca. También se pudo percibir, que antes de estos hechos, hay otros fenómenos afectando de manera negativa a la imagen de la compañía, concretamente se observa en la figura 5 como el 29 de enero de 2017 los tweets negativos alcanzan a un máximo superando los nueve mil.

Figura 5.





Figura 6.



Una vez realizado el análisis de contenido de los tweets, se confirmó la existencia de otros sucesos afectando a la reputación de la compañía antes de que ocurran los hechos estudiados. Los temas principales que se pueden distinguir son “muslim ban”, “fascist” o “delete app”. Una vez se publicó el blog por parte de la extrabajadora, se pueden identificar temas vinculados con “sexual harassment” o “sexism” y en las estadísticas del texto aparecen entre las 50 palabras más usadas términos como “woman” o “harassment”.

5. Conclusion.

La rápida expansión de las redes sociales y el uso que la población les da, hace indispensable para las empresas la automatización de las técnicas de análisis de sentimiento. Tener un conocimiento constante de la opinión del público es de gran importancia a la hora de tomar decisiones y responder a oleadas negativas.

En este estudio, se utilizó el modelo preentrenado Siberett/twitter-roberta-base-sentiment-latest-finetune, con el objetivo de realizar una tarea de clasificación. Este modelo se comparó con otros clasificadores (SVM y Xlnet), reportando *un accucary* y *un macro avg F1* superiores.

Los resultados de este estudio nos permiten concluir que los incidentes relacionados con el acoso sexual tienen un efecto negativo directo en la imagen de las marcas, se percibió una respuesta activa por parte del público, por lo que es recomendable una actuación rápida y contundente por parte de las empresas ante este tipo de hechos. Este efecto adverso puede distinguirse en los cambios de temáticas identificados en los tweets y en sus distribuciones diarias. En los días consecutivos a los hechos estudiados se observó su impacto en el incremento de tweets negativos diarios. En el caso Activision Blizzard se vio como su índice de reputación se redujo considerablemente, pasando de valores en torno a cero, a valores de -0,55. En el caso Uber, el índice de reputación de la compañía se mantuvo en torno al -0.45, siguiendo una tendencia negativa tras encadenar dos sucesos adversos para la marca.

En el futuro, se intentará plantear un análisis comparativo entre la tendencia de la reputación de las compañías y su precio de mercado, con el objetivo de observar si hay correlación entre estas medidas.

Bibliografía.

- [1] Vaswani, A., Shazer, Noam., Parmar, N., Uszkoreit, J., N Gomez, A N., Kaiser, L., Polosukhin, I. (2017, June 12). Attention Is All You Need. arXiv.org. <https://arxiv.org/abs/1706.03762>.
- [2] Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, Tim., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite, Y., Plu, J., Xu, C. Le Scao, T., Gugger, S., Drame, M., Lhoest, Q., Rush, A. (2020). Transformers: State-of-the-Art Natural Language Processing. ACL Anthology. <https://aclanthology.org/2020.emnlp-demos.6/>
- [3] Kim, H. (2021, December 21). A Study on Brand Image Analysis of Gaming Business Corporation using KoBERT and Twitter Data. <https://koreascience.kr/>. <https://koreascience.kr/article/JAKO202107656123606.pdf>
- [4] Rahman, M. W. U., Shao, S., Satam, P. Hariri, S., Padilla, C., Taylor, Z., Nevarez, C. (2022, October 23). A BERT-based Deep Learning Approach for Reputation Analysis in Social Media. arXiv.org. <https://arxiv.org/abs/2211.01954>.
- [5] Barbieri, F., Camacho-Collados, J., Neves, L., Espinosa-Anke, L. (2020, October 23). TweetEval: Unified Benchmark and Comparative Evaluation for Tweet. . . arXiv.org. <https://arxiv.org/abs/2010.12421>
- [6] JustAnotherArchivist (2021). snsrape: A social networking service scraper in Python. <https://github.com/JustAnotherArchivist/snsrape>.
- [7] Hugging Face – The AI community building the future. (n.d.). <https://huggingface.co>
- [8] JamSpell - Spell Checking Library. (n.d.). <https://jampspell.com>
- [9] Joachims, T. (1998). Text categorization with Support Vector Machines: Learning with many relevant features. SpringerLink. <https://link.springer.com/content/pdf/10.1007/BFb0026683.pdf?pdf=inline%20link>.
- [10] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., Stoyanov, V. (2019, July 26). RoBERTa: A Robustly Optimized BERT Pretraining Approach. arXiv.org. <https://arxiv.org/abs/1907.11692>.
- [11] Devlin, J., Chang, M., Lee, K., Toutanova, K. (2018b, October 11). BERT: Pre-training of Deep Bidirectional Transformers for Language. arXiv.org. <https://arxiv.org/abs/1810.04805>
- [12] Muller, B. (2022, March 3). BERT 101 - State Of The Art NLP Model Explained. <https://huggingface.co/>. <https://huggingface.co/blog/bert-101>
- [13] Loureiro, D., Barbieri, F., Neves, L., Anke, L E., Camacho-Collados, J. (2022, February 8). TimeLMs: Diachronic Language Models from Twitter. arXiv.org. <https://arxiv.org/abs/2202.03829>.
- [14] Yang, Z., Dai, Z., Yang, Y., Salakhutdinov, R., Le, Q V. (2019, June 19). XLNet: Generalized Autoregressive Pretraining for Language Understanding. arXiv.org. <https://arxiv.org/abs/1906.08237>.
- [15] Dakshi T. Kapugama Geeganage (2018, April). Concept Embedded Topic Modeling Technique. <https://dl.acm.org/>. <https://dl.acm.org/doi/10.1145/3184558.3186571>
- [16] Grootendorst, M. (2022, March 11). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv.org. <https://arxiv.org/abs/2203.05794>